

Informe Académico: Evaluación de Eficiencia Algorítmica y Rendimiento Web mediante la Plataforma 'DataBench AI'

Carrera: Ingeniería Civil Informática en inteligencia artificial **Asignatura:** CHATGPT Y TECNOLOGIAS DE IAG PARA EL TRABAJO ACADEMICO

1. Síntesis de la investigación desarrollada

Como estudiante investigador en el área de la Ingeniería Civil Informática, la presente investigación aborda el dilema crítico entre la maximización de la precisión y el control del costo computacional en los sistemas contemporáneos de Inteligencia Artificial (IA).

Definición del Problema y Antecedentes Teóricos

En los últimos años, la comunidad científica ha priorizado masivamente la obtención de resultados de "estado del arte" (*State-of-the-Art* o SOTA) mediante el incremento exponencial de recursos de cómputo, una tendencia denominada **Red AI** 1-3. Entre 2012 y 2018, la cantidad de cómputo utilizada para entrenar los modelos de *deep learning* más destacados creció en un factor de 300.000x, duplicándose cada pocos meses 1, 4, 5.

El costo computacional de un resultado en aprendizaje automático (R) se puede formalizar de manera simplificada mediante la relación directa con tres variables clave:

$$\text{Cost}(R) \propto E \cdot D \cdot H$$

donde E representa el costo de procesar un único ejemplo, D es el tamaño del conjunto de datos de entrenamiento y H es la cantidad de experimentos de hiperparámetros ejecutados 6, 7. A pesar del gran gasto de recursos que esto involucra, la relación entre el desempeño alcanzado por el modelo y la escala del dataset o la complejidad del algoritmo obedece a una ley de **rendimientos decrecientes de carácter logarítmico**; es decir, para obtener una ganancia lineal en precisión se requiere un aumento exponencial en el volumen de datos o parámetros 3, 8, 9.

Un análisis empírico de las publicaciones en conferencias de primer nivel (como ACL, NeurIPS y CVPR) evidencia que entre el 75% y el 90% de los artículos se enfocan exclusivamente en optimizar la precisión, mientras que solo entre el 10% y el 20% consideran la eficiencia computacional como una contribución principal 6, 10, 11. En respuesta a esta asimetría, la corriente de **Green AI** promueve evaluar la eficiencia (medida en operaciones de punto flotante o FPO, tiempo de ejecución y uso de memoria) como un criterio primario a la par de la precisión 12-16.

Por otro lado, la evolución de entornos de ejecución web como **TensorFlow.js** ha abierto la posibilidad de realizar cómputo en el lado del cliente (*on-device computation*), lo que garantiza privacidad de datos, baja latencia y eliminación de costos de infraestructura en servidores centrales 17-19. Sin embargo, la ejecución en el navegador impone serios desafíos de ingeniería: JavaScript opera sobre un modelo **monohilo** (*single-threaded* o hilo de interfaz de usuario) 20, 21, donde los procesos intensivos no bloqueantes requieren arquitecturas asíncronas o aceleración por hardware mediante APIs como WebGL para evitar el congelamiento de la aplicación 21-25.

Pregunta de Investigación y Hallazgos Proyectados

Frente a este marco teórico, formulo la siguiente **pregunta de investigación**: *¿De qué manera el escalamiento en el volumen del conjunto de datos ($\|D\|$) y la complejidad estructural del algoritmo (Regresión Logística vs. Random Forest) afectan la relación de compromiso (trade-off) entre la precisión (Accuracy) y el tiempo de respuesta en milisegundos dentro de un entorno web monohilo?*

Se proyecta que el incremento del dataset mostrará una curva de exactitud con saturación logarítmica, mientras que el tiempo de ejecución y el consumo de recursos en el navegador crecerán de manera lineal o superlineal. Asimismo, se proyecta que algoritmos de ensamble como **Random Forest** sufrirán una penalización temporal desproporcionada en comparación con modelos lineales como la **Regresión Logística**, evidenciando los límites prácticos del cómputo cliente en la web.

2. Aplicación digital (Lógica y propósito)

Para llevar a cabo la recolección empírica de métricas, desarrollé la aplicación web interactiva '**DataBench AI**', construida utilizando estándares web nativos (**HTML5, CSS3 y JavaScript ES6+**).

Propósito y Lógica del Sistema


DataBench AI no está diseñada para el diagnóstico ni la predicción clínica de pacientes reales. Su propósito metodológico es operar como un **laboratorio experimental en el navegador** para cuantificar el costo computacional frente al rendimiento predictivo.


La aplicación procesa un dataset sintético con variables fisiológicas clave:

- Hemoglobina glicosilada ($\|HbA1c\|$)
- Presión arterial sistólica
- Edad
- Índice de Masa Corporal ($\|IMC\|$)

El usuario puede manipular experimentalmente el tamaño de la muestra ($\|D\|$) y seleccionar entre dos clasificadores con demandas computacionales contrastantes:

1. **Regresión Logística**: Modelo lineal de bajo costo de procesamiento por muestra ($\|E\|$).
2. **Random Forest**: Modelo de ensamble basado en múltiples árboles de decisión con mayor costo $\|E\|$ e inferencia intensiva.





Implementación Técnica en JavaScript


Para cronometrar de forma precisa los tiempos de entrenamiento e inferencia en el lado del cliente o servidor, la aplicación utiliza la API de temporización de alta resolución de JavaScript (`performance.now()`), garantizando una precisión sub-milisegundo.

Dado que la ejecución de scripts en el navegador comparte el hilo principal con el renderizado de la interfaz y la gestión de eventos 20, 21, se implementaron patrones **asíncronos basados en Promesas y fragmentación de tareas (*event loop*)** 21, 26. Esto impide que el navegador marque la página como congelada durante el entrenamiento de Random Forest sobre volúmenes grandes de datos.

La aplicación integra un módulo de registro que exporta automáticamente las decisiones del usuario y las métricas resultantes en formatos estandarizados **JSON** y **CSV**. Esta función justifica su valor metodológico al permitir la auditoría de datos, la reproducibilidad de las pruebas e integraciones posteriores con herramientas de análisis estadístico fuera del navegador.

3. Plan futuro de medición cualitativo-cuantitativa

Para evaluar de forma rigurosa la interacción del usuario y el comportamiento del sistema, propongo una **estrategia metodológica mixta (triangulación de datos)**.



• Tiempo de ejecución (ms)	• Percepción de congelamiento
• Tasa de Accuracy (%)	• Justificación de elección
• Tamaño del dataset (D)	• Observaciones directas
• Frecuencia de selección post-prueba	• Cuestionario

Componente Cuantitativo (Automatizado por JS)

La aplicación **DataBench AI** registrará automáticamente en los archivos de log:

- **Tiempo de ejecución (T_{ejec}):** Milisegundos transcurridos durante las fases de ajuste de datos y predicción.
- **Tasa de exactitud (Accuracy):** Porcentaje de clasificaciones sintéticas correctas sobre la muestra de prueba.
- **Volumen del dataset (D):** Cantidad exacta de registros sintéticos procesados.
- **Frecuencia de selección de modelo:** Conteo de elecciones entre Regresión Logística y Random Forest por parte del usuario.


Componente Cualitativo (Interacción y Percepción)


Se complementará el registro automático mediante:

- **Observación directa del investigador:** Anotaciones estructuradas sobre congelamientos de pantalla (*jank*), retardos de renderizado y comportamientos anómalos del navegador.
- **Cuestionario breve post-prueba:** Formulario administrado al usuario al finalizar la experiencia para registrar la justificación detrás de la elección de cada modelo, su nivel de tolerancia al tiempo de espera y la percepción subjetiva de fluidez en la plataforma web.

4. Propuesta de protocolo de prueba

Diseñé el siguiente protocolo experimental estandarizado para ejecutar la evaluación de manera controlada y repetible:





- **Pregunta de Investigación:** ¿Cómo afecta el escalamiento del volumen de datos a la toma de decisiones del usuario al ponderar exactitud versus tiempo de procesamiento en el cliente?
- **Experiencia:** Sesión individual de 15 minutos de interacción guiada con la plataforma **DataBench AI**, donde el participante debe entrenar, comparar y evaluar los modelos variando los parámetros de entrada.
- **Participantes:** Muestra de 20 a 30 estudiantes avanzados de Ingeniería Civil Informática o analistas de datos con conocimientos básicos de machine learning.
- **Condiciones de Prueba:** Entorno de laboratorio informático controlado con computadores de arquitectura idéntica (procesador, memoria RAM y versión de navegador estandarizados), eliminando sesgos de hardware en las mediciones de tiempo de ejecución 27, 28.
- **Instrumentos de Registro:**
- **Logs automáticos:** Descarga del archivo JSON/CSV generado por la aplicación al término de la sesión.
- **Formulario final:** Cuestionario digital al finalizar la prueba para evaluar usabilidad y razonamiento analítico.

5. Indicadores o criterios a observar y medir

Para analizar la evidencia recopilada empíricamente, se definen los siguientes indicadores cuantitativos y cualitativos:

Indicadores Técnicos

1. **Ratio de Eficiencia Algorítmica (REA):**
2.
$$\text{REA} = \frac{\text{Accurac}y (\%)}{\text{Tiempo de Ejecución (ms)}}$$
3. Métrica inspirada en las propuestas de Green AI para medir cuánta precisión se obtiene por cada unidad de tiempo invertida 13, 14, 16.
4. **Tiempo Promedio por Muestra (E):**
5.
$$E = \frac{T_{\text{ejec}}}{D}$$
6. Medición de la latencia unitaria de inferencia en milisegundos 7, 29.
7. **Tasa de Escalabilidad Temporal (ΔT):** Cociente entre el tiempo de ejecución al multiplicar por 10 el volumen de datos ($10D$) y el tiempo base sobre (D) 7, 9.
8. **Índice de Percepción Cualitativa del Compromiso (PCC):** Puntaje (escala Likert de 1 a 5) obtenido en el formulario respecto a la satisfacción del usuario con la velocidad frente a la precisión obtenida.

Análisis de la Evidencia Empírica

Los datos cuantitativos extraídos de los registros CSV/JSON se procesarán mediante pruebas estadísticas de correlación (Pearson/Spearman) y análisis de varianza (ANOVA) para determinar si las diferencias de tiempo entre Regresión Logística y Random Forest son estadísticamente significativas a medida que $\|D\|$ crece. Los datos cualitativos se codificarán mediante análisis temático para identificar patrones de tolerancia a la latencia en aplicaciones web.

6. Aporte de la investigación a la disciplina

Esta investigación aporta un valor metodológico significativo a la **Ingeniería Civil Informática**, demostrando cómo la creación de herramientas digitales interactivas mediante tecnologías web y herramientas asistidas por generación de software permite llevar las discusiones teóricas de la computación a experimentos empíricos medibles.

En primer lugar, el proyecto evidencia que el uso de tecnologías web como JavaScript y arquitecturas en el navegador no solo sirve para la construcción de interfaces de usuario, sino también para implementar **laboratorios de medición empírica de rendimiento algorítmico** 17, 18, 30.

En segundo lugar, al vincular de manera explícita el concepto de **Green AI** 12, 15 con las restricciones técnicas del cómputo cliente (como la naturaleza monohilo de JavaScript y la aceleración mediante WebGL) 20-22, 24, esta investigación aporta rigor metodológico al diseño de arquitecturas de Inteligencia Artificial basadas en la web. Permite a los futuros ingenieros proyectar sistemas donde la sostenibilidad ambiental, la baja latencia y el costo computacional se evalúen con el mismo nivel de exigencia formal que la exactitud predictiva 1, 12, 17.

💡 ¿Te gustaría que redacte la plantilla de código en JavaScript para el módulo de medición con `performance.now()` y la exportación de logs a CSV/JSON para integrarla directamente en 'DataBench AI'?